

**HACKATON BOEHRINGER
2025**

ENFERMEDAD CRÓNICA RENAL

**EQUIPO 5
DEBUG QUEENS**

ÍNDICE

INTRODUCCIÓN	2
PLANIFICACIÓN	2
TEORIA MÉDICA	4
¿Cuáles son los síntomas de esta enfermedad?	4
¿Qué causa la enfermedad?	5
PLAN TÉCNICO	8
Definición del Problema y Estrategia de Datos	8
Estrategia de Datos y Pipeline de Preprocesamiento	8
1. Selección del Dataset (Smart Data)	9
2. Limpieza y Estandarización	9
3. Ingeniería de Características (Feature Engineering)	9
4. Análisis Exploratorio y Validación Visual (EDA)	10
Gradient boosting (XGBoost):	12
1. Manejo nativo de valores nulos (Missing Values)	12
2. Captura de "No Linealidades" y Umbrales Médicos	13
3. Importancia de Variables	13
4. Estrategia de "Smart Data" y Robustez en Escenarios Limitados	13
4.1. Arquitectura Regularizada (XGBoost) y balanceada	14
4.2. Validación Cruzada Estratificada (Stratified K-Fold)	14
4.3. Alta densidad de información ("Smart Data")	14
5. Métricas de evaluación clínica: Más allá del "Accuracy"	14
5.1. Recall (Sensibilidad)	15
5.2. F1-Score como Medida de Equilibrio	15
5.3. Transparencia mediante Matriz de Confusión	15
5.4 Resultados	15
INTERFAZ GRÁFICA	20
CONCLUSIÓN	29

INTRODUCCIÓN

La enfermedad renal crónica es una patología silenciosa que puede avanzar durante años sin mostrar síntomas evidentes, lo que dificulta su detección temprana y retrasa el inicio de un tratamiento adecuado. En atención primaria, los médicos deben interpretar múltiples parámetros analíticos y antecedentes clínicos, una tarea compleja que puede generar variabilidad en las decisiones.

Con este proyecto buscamos desarrollar una herramienta clínica inteligente capaz de analizar la historia y la analítica de cada paciente, identificar patrones de riesgo y ofrecer una evaluación objetiva y estandarizada. Nuestro objetivo es facilitar una detección precoz, mejorar la toma de decisiones y apoyar a los profesionales sanitarios en la identificación de pacientes que podrían beneficiarse de un control más estrecho o de una prueba confirmatoria como el Filtrado Glomerular.

Este sistema combina el conocimiento médico con técnicas avanzadas de inteligencia artificial para proporcionar una herramienta accesible, interpretativa y útil en el día a día clínico.

PLANIFICACIÓN

El equipo está formado por dos antiguas compañeras de trabajo. Por un lado, Eva estudia Ingeniería Biomédica, y por otro, Miriam que estudia Inteligencia Artificial. Ambas sabemos programar y tenemos conocimientos de bases de datos, pero Eva aporta una comprensión más profunda del ámbito médico, mientras que Miriam destaca en la parte técnica teniendo en cuenta los conocimientos médicos mediante el procesamiento de datos y el diseño de un modelo de IA.

En la fase inicial de búsqueda, Eva se ha centrado en profundizar en la información médica relevante, mientras que Miriam ha investigado qué modelos pueden resultar más adecuados. Después, hemos compartido los resultados de nuestras investigaciones y, a partir de ello, hemos implementado el código de forma conjunta.

A continuación, hemos seleccionado la base de datos UCI CKD descargada desde Kaggle. Hemos realizado la limpieza del dataset, hemos entrenado el modelo (Gradient Boosting) y hemos calculado las métricas de rendimiento. Finalmente, hemos desarrollado una demo interactiva utilizando Streamlit.




Fig 1. Planning de tareas

TEORIA MÉDICA

¿Cuáles son los síntomas de esta enfermedad?

Hay distintos síntomas que pueden aparecer cuando tenemos una enfermedad renal crónica.

Urinarios:

- Mayor o menor producción de orina
- Orina espumosa
- Orina oscura o con sangre
- Dificultad para orinar

Síntomas generales

Cansancio i falta de energia
Debilitat
Dificultad de concentración
Somnolencia
Dolor de cabeza

Síntomas digestivos

Náuseas
Vómitos
Pérdida de apetito
Sabor metálico en la boca
Mal aliento

Síntomas cardiovasculares

Hinchazón (edemas en piernas, tobillos, cara o manos)
Presión arterial alta
Latidos cardíacos irregulares
Dolor o presión

Síntomas neuromusculares

Calambres musculares (por la noche)
Hormigueo o entumecimiento
Confusión o dificultad cognitiva
Convulsiones
Coma

Síntomas dermatológicos

Piel seca

Picor intenso

Cambios en el color de la piel

Síntomas respiratorios

Dificultad para respirar

Síntomas del metabolismo óseo

-Dolor óseo

-Fragilidad

¿Qué causa la enfermedad?

La **hipertensión** es una de las causas principales de daño renal, representando aproximadamente el 80% de los casos. Cuando los riñones están dañados, pierden la capacidad de regular la presión arterial adecuadamente, lo que genera un círculo vicioso que empeora tanto la función renal como la propia hipertensión. Alrededor del 95% de los casos, la hipertensión está relacionada con varios factores.

Entre ellos se encuentran **la diabetes mellitus** donde el cuerpo no produce suficiente insulina y por lo tanto la **glucosa en sangre** se ve elevada. También existen enfermedades que pueden provocar hipertensión secundaria y contribuir al daño renal, como el lupus, la esclerodermia, las enfermedades cardíacas, la presencia de edema en los tobillos, la anemia que puede aparecer hasta en el 60% de los pacientes con **infecciones renales**, **enfermedad coronaria** defectos congénitos como la **poliquistosis renal o lesiones directas en el riñón**.

Además de los factores mencionados, también pueden contribuir a esta enfermedad son las **enfermedad coronaria o las obstrucciones urinarias**.

Una **creatinina alta** significa que el riñón filtra peor; entonces si está alta, el Filtrado Glomerular disminuye; por lo tanto, el riñón no está eliminando los desechos como debería y es un marcador de insuficiencia renal.

Una **albúmina alta** en orina indica daño en los glomérulos, por lo tanto puede ser signo de enfermedad renal crónica.

También, **la creatinina** será un factor alterado, es decir, encontraremos pacientes con creatinina más alta porque los riñones no la eliminan bien,

El riesgo de enfermedad renal también **aumenta con la edad**. Antes de los 50 años es muy bajo. Entre los 50 y 60 años se sitúa alrededor del 10%, a partir de los 60 años aumenta al 20–30% y desde los 70–75 años sube al 30–40%. Entonces, nuestra paciente Laura tiene una alta probabilidad de tener la enfermedad renal crónica.

El 5% restante de causas de enfermedad renal incluye alteraciones de las glándulas paratiroides, acromegalia (un exceso de hormona del crecimiento), tumores en las glándulas suprarrenales o en la glándula pituitaria y el embarazo.

¿Qué pasa con otros factores?

Aunque factores como el consumo de alcohol, el tabaquismo, los anticonceptivos influyen en el riesgo renal, no los incluimos en el modelo porque nuestro dataset no los contiene de forma fiable. No obstante, consideramos que preferimos trabajar únicamente con variables objetivas y disponibles para asegurar la validez clínica del sistema.

Hemos tenido la oportunidad de hablar con una médica, quien nos ha explicado con más detalle en qué consiste esta enfermedad, cuáles son sus síntomas y cuáles pueden ser sus causas.

A partir de esta analítica relacionada con la enfermedad renal crónica, podemos observar que el/la paciente presenta valores aumentados de glucosa (141 mg/dL), urea (62 mg/dL) y creatinina (1.19 mg/dL). Estos resultados refuerzan la parte teórica que hemos estudiado.

DATOS ADICIONALES-Información clínica		U99.01 - Insuficiencia renal crónica -	
Datos clínicos aportados			
HEMATOLOGÍA-Hematimetría			
Leucocitos	5.61	x 10 ⁹ /L	[4.0 - 11.5]
Eritrocitos	4.25	mill/mm ³	[4.0 - 4.8]
Hemoglobina	12.5	g/dL	[12.0 - 16.0]
Hematocrito	39.7	%	[36.0 - 45.0]
V.C.M.	93.3	µm ³	[80.0 - 99.0]
H.C.M.	29.4	pg	[26.0 - 32.0]
C.H.C.M.	31.5	g/dL	[31.0 - 36.0]
RDW	14.3	%	[0.0 - 16.0]
Plaquetas	118.0	x 10 ⁹ /L	[130.0 - 450.0]*
MPV	10.5	fL	[7.0 - 11.0]
Linfocitos %	29.2	%	[19.0 - 45.0]
Monocitos %	6.5	%	[3.4 - 12.0]
Neutrófilos %	58.5	%	[40.0 - 74.0]
Eosinófilos %	3.9	%	[0.0 - 7.0]
Basófilos %	0.6	%	[0.0 - 1.6]
LUCI.CYC	1.3	%	[0.0 - 5.0]
Linfocitos	1.64	x 10 ⁹ /L	[1.0 - 4.0]
Monocitos	0.37	x 10 ⁹ /L	[0.2 - 1.0]
Neutrófilos	3.28	x 10 ⁹ /L	[2.5 - 7.5]
Eosinófilos	0.22	x 10 ⁹ /L	[0.0 - 0.4]
Basófilos	0.03	x 10 ⁹ /L	[0.0 - 0.2]
Hipocromía	++		
Firmado por: _____			
BIOQUÍMICA-Sero / Plasma			
Glucosa	141.0	mg/dL	[70.0 - 110.0]*
Urea	62.0	mg/dL	[16.0 - 50.0]*
Creatinina	1.19	mg/dL	[0.65 - 1.42]*
Acido Úrico	5.5	mg/dL	[2.4 - 5.7]
Sodio	144.0	mEq/L	[135.0 - 145.0]
Potasio	4.2	mEq/L	[3.5 - 5.0]
Proteínas totales	6.8	g/dL	[6.0 - 8.0]
Albumina (verde de bromocresol)	4.4	g/dL	[3.5 - 5.0]
Calcio	9.6	mg/dL	[8.5 - 10.1]
Fósforo	3.6	mg/dL	[2.7 - 4.5]
Triglicéridos	76.0	mg/dL	[0.0 - 150.0]
Colesterol	129.0	mg/dL	[0.0 - 200.0]
HDL - Colesterol	56 mg/dL [Valor Ref.: >50]		
LDL - Colesterol (Formula Friedewald)	58.0	mg/dL	[-]
Valores recomendados según el R.C.V. del paciente:			
V. Recomendado en Prevención secundaria y R.C.V. muy alto: < 55 mg/dL.			
V. Recomendado en R.C.V. alto: < 70 mg/dL.			
V. Recomendado en R.C.V. moderado: < 100 mg/dL.			
V. Recomendado en R.C.V. bajo: < 116 mg/dL.			
No HDL - Colesterol (calculado)			
	73.0	mg/dL	[-]
Valores recomendados según el R.C.V. del paciente:			
V. Recomendado en Prevención secundaria y R.C.V. muy alto: < 85 mg/dL.			

Fotografía 1. Analítica de enfermedad renal crónica

Cuando un paciente tiene riesgo de tener esta enfermedad, un parámetro muy importante a mirar es el Filtrado Glomerular.

¿Qué es el Filtrado Glomerular?

Es una prueba que permite evaluar de forma precisa la capacidad real del riñón para filtrar toxinas y desechos de la sangre. Es una prueba esencial que permite confirmar si existe un deterioro funcional, determinar la gravedad y decidir si es necesario un tratamiento o un control más estrecho.

¿Por qué el filtrado glomerular?

En las analíticas habituales, con pacientes con sospecha de enfermedad renal, se incluyen parámetros como la creatinina, albúmina, etc. y el Filtrado Glomerular Estimado (FGe). Este último es un valor fundamental que permite conocer la capacidad del riñón para filtrar sustancias de desecho de la sangre.

Los valores de este filtrado son:

≥ 90 ml/min: función renal normal

60–89: disminución ligera

45–59: disminución ligera-moderada

30–44: disminución moderada

15–29: disminución severa

< 15: fallo renal

Por este motivo, cuando se detecta un riesgo moderado o alto, es necesario solicitar una analítica del Filtrado Glomerular, ya que este determina de manera fiable el grado de funcionamiento renal y permite confirmar si existe una disminución significativa de la función del riñón.

PLAN TÉCNICO

Definición del Problema y Estrategia de Datos

Objetivo del Sistema (Risk Scoring): El propósito central no es solo diagnosticar el estado actual del paciente, sino desarrollar una capacidad de **predicción de riesgo** (*Risk Scoring*). Buscamos identificar qué perfiles, aparentemente estables hoy, tienen una alta probabilidad de desarrollar Enfermedad Renal Crónica (ERC) en el futuro si no se interviene.

Naturaleza de los Datos (Dataset UCI CKD): Trabajamos con datos tabulares estructurados procedentes del *UCI Machine Learning Repository*. Vemos que nuestro dataset tiene un desbalance de clases (60% de sanos vs 40% de enfermos). Esto es favorable para el entrenamiento. En lugar de aplicar técnicas agresivas de generación de datos sintéticos (como SMOTE) que podrían introducir ruido, optamos por el uso de **Class Weights** (pesos de clase) en el algoritmo para penalizar más el error en la clase minoritaria sin alterar la veracidad de los datos originales.

Métricas de Éxito Clínico: Descartamos la "Exactitud" (*Accuracy*) como métrica principal. En el contexto de este reto, la prioridad clínica es minimizar los Falsos Negativos (no detectar a un enfermo).

- **Prioridad:** Maximizamos el **Recall (Sensibilidad)**.
- *Justificación:* Es aceptable que el sistema genere una falsa alarma (Falso Positivo) que el médico pueda descartar tras una revisión, pero es inadmisibles que el sistema pase por alto a un paciente con riesgo real de ERC. Evaluaremos el balance final mediante el **F1-Score**.

Filosofía de "Caja Blanca": Los profesionales sanitarios requieren transparencia. El uso de algoritmos de "Caja Negra" (como Redes Neuronales profundas) dificultaría la adopción clínica al no poder justificar el motivo de una alerta. Por ello, la arquitectura se basa en modelos explicables (**Gradient Boosting**) apoyados en una fuerte ingeniería de características (*Feature Engineering*) que nos permita contextualizar no solo los valores puntuales, sino la historia clínica del paciente.

Estrategia de Datos y Pipeline de Preprocesamiento

Para dar respuesta al reto de identificar pacientes en riesgo de Enfermedad Renal Crónica (ERC) basándonos en su historia clínica, hemos diseñado una estrategia de datos rigurosa centrada en la calidad clínica y la interpretabilidad.

1. Selección del Dataset (Smart Data)

Hemos seleccionado el dataset de referencia **"Chronic Kidney Disease"** del repositorio UCI Machine Learning.

- **Justificación Clínica:** Este conjunto de datos contiene 400 pacientes y 25 variables que coinciden exactamente con los biomarcadores de riesgo solicitados en el reto, incluyendo datos de analítica (Creatinina, Albúmina, Potasio), constantes vitales (Presión Arterial) y antecedentes (Diabetes, Hipertensión).
- **Representatividad:** El dataset presenta una distribución de clases de aproximadamente 60% enfermos (`ckd`) y 40% sanos (`notckd`). Este balance natural es ideal para el entrenamiento, evitando los sesgos extremos típicos de bases de datos hospitalarias sin filtrar.

2. Limpieza y Estandarización

Los datos originales presentaban inconsistencias de formato ("ruido") que impedían su procesamiento directo. Hemos implementado un módulo de limpieza automatizado (`data_processor.py`) que realiza:

- **Saneamiento de Texto:** Eliminación de caracteres ocultos (tabuladores `\t`, espacios) y estandarización de etiquetas inconsistentes.
- **Gestión de Nulos:** Detección y conversión de marcadores no estándar (?) a valores nulos reales (`NaN`), permitiendo que nuestro modelo XGBoost gestione la incertidumbre de forma nativa sin imputaciones artificiales.
- **Codificación:** Transformación de variables categóricas a numéricas binarias (0/1) para su ingesta por el algoritmo.

3. Ingeniería de Características (Feature Engineering)

Para cumplir con el requisito de evaluar la "historia clínica" y no solo el estado actual, hemos enriquecido el dataset generando nuevas variables sintéticas de alto valor predictivo:

- **Score de Comorbilidad (`history_score`):** Una variable agregada que suma los antecedentes patológicos clave (Hipertensión + Diabetes + Enfermedad Coronaria). Esto permite al modelo ponderar el riesgo acumulado de un paciente pluripatológico frente a uno sin antecedentes.

$$HistoryScore = \text{Hipertensión (1/0)} + \text{Diabetes (1/0)} + \text{Enf. Coronaria (1/0)}$$

El HistoryScore permite al modelo XGBoost segmentar rápidamente a los pacientes según su complejidad médica previa, simulando el juicio clínico de un médico de familia que ve un historial "pesado".

- **Alerta de hipertensión descontrolada (bp_alarm):** Un indicador binario que detecta si el paciente supera los umbrales de riesgo cardiovascular (>140 mmHg) o tiene un diagnóstico previo, facilitando la detección temprana de factores causales de la ERC.

$$BPAlarm = 1 \quad \text{si} \quad (BP > 140) \quad \text{Ó} \quad (\text{Diagnóstico Hipertensión} == 1)$$

Crea una "Bandera Roja" binaria. Ayuda al modelo a no confundirse con un paciente hipertenso que hoy tiene la tensión bien controlada por medicación, pero cuyo riñón ya ha sufrido daño histórico.

- **Ratio de Riesgo Renal (renal_risk_ratio):** Una variable de interacción que combina los niveles de Creatinina Sérica y Albúmina, dos de los marcadores más potentes de daño renal, amplificando la señal de riesgo en estadios tempranos.

$$RenalRiskRatio = \text{Creatinina Sérica} \times (\text{Albúmina} + 1)$$


Es una variable de interacción. Al multiplicar ambos marcadores, amplificamos la señal. Si ambos están ligeramente alterados, el resultado se dispara, alertando al modelo de un fallo renal incipiente que pasaría desapercibido mirando las variables por separado.

4. Análisis Exploratorio y Validación Visual (EDA)

Antes de someter los datos al algoritmo de aprendizaje, hemos realizado una auditoría visual mediante scripts de generación automática (visualization.py) para confirmar dos hipótesis críticas: que el dataset no presenta sesgos técnicos y que los datos respetan la fisiología renal conocida.


4.1. Verificación de balance de Clases Confirmamos visualmente que la distribución entre pacientes sanos y enfermos mantiene una proporción adecuada (aprox. 60/40). A diferencia de los datasets de fraude o enfermedades raras (1:1000), este balance natural permite entrenar el modelo maximizando la sensibilidad sin depender exclusivamente de datos sintéticos.

Fig 2. Distribución de clases en el dataset procesado, mostrando un escenario equilibrado ideal para el aprendizaje supervisado.



4.2. Poder Discriminante de Biomarcadores (Creatinina) Para validar la integridad clínica de los datos, analizamos la distribución de la **Creatinina Sérica (sc)**, el marcador "Gold Standard" de la función renal. El gráfico de caja (Boxplot) revela una distinción nítida: los pacientes diagnosticados con ERC (Clase 1) presentan niveles de creatinina significativamente más elevados y dispersos, mientras que los pacientes sanos (Clase 0) se mantienen en un rango compacto y bajo. Esta separación visual confirma que la variable tiene un alto poder predictivo y que los datos no contienen ruido aleatorio.

Fig 3. Análisis de impacto de la Creatinina Sérica. Se observa una clara separación de rangos entre pacientes sanos (0) y enfermos (1), validando la calidad fisiológica del dato.



4.3. Matriz de Correlaciones Clínicas Finalmente, evaluamos cómo interactúan nuestras variables mediante un mapa de calor. El análisis confirma las hipótesis médicas del equipo:

- **Correlación Positiva Fuerte:** La enfermedad (**classification**) correlaciona intensamente con nuestra variable sintética **history_score** y con la Albúmina (**al**), validando nuestra ingeniería de características.
- **Correlación Negativa:** Observamos una fuerte relación inversa con la Hemoglobina (**hemo**), confirmando que la anemia es un indicador clave asociado al daño renal, tal y como se describe en el caso de uso del reto ("paciente cansada").




Fig 4. Mapa de calor mostrando las correlaciones más fuertes. Nótese la alta relevancia de la variable generada 'history_score' y los biomarcadores clásicos.

Gradient boosting (XGBoost):

Para la resolución del Reto 2, hemos optado por una arquitectura basada en **Gradient Boosting (XGBoost)**. Este método es **un modelo supervisado** que construye múltiples árboles de decisión de forma secuencial, donde cada árbol corrige los errores del anterior. Este proceso hace que el árbol sea estable, ya que no depende de un único árbol, sino de una suma de árboles pequeños que reducen progresivamente el error.

Dado que trabajamos con **datos tabulares** estructurados (historia clínica), los modelos basados en árboles de decisión (Decision Trees) y sus variantes avanzadas como el Boosting superan sistemáticamente al Deep Learning en rendimiento y eficiencia computacional.

A continuación, detallamos las 4 justificaciones técnicas de esta elección.

1. Manejo nativo de valores nulos (Missing Values)

El dataset clínico (UCI CKD) presenta huecos en variables como la glucosa o la presión arterial. La solución clásica de imputar con la media (rellenar con el promedio) introduce un riesgo de sesgo, ya que inventa datos en pacientes críticos.

XGBoost permite trabajar con valores nulos de forma nativa. Durante el entrenamiento, el algoritmo aprende una "dirección por defecto" óptima (izquierda o derecha en el nodo del árbol) para los valores NaN. De este modo, el modelo es capaz de aprender si la *ausencia del dato* es en sí misma un factor de riesgo (ejemplo: no se midió la glucosa porque el paciente estaba aparentemente sano), ahorrando horas de preprocesado y evitando la introducción de ruido estadístico.

2. Captura de "No Linealidades" y Umbrales Médicos

La fisiología humana no es lineal. Factores como la edad o la presión arterial no aumentan el riesgo de forma aritmética constante. Por ejemplo, tener 60 años en sí, no es crítico, pero la combinación `(Edad > 60) AND (Hipertensión = True)` dispara el riesgo exponencialmente.

Al basarse en árboles de decisión, XGBoost opera creando cortes rectangulares en el espacio de datos, generando reglas del tipo: `IF (Creatinina > 1.2) AND (Edad > 50) THEN Riesgo Alto`. Esta lógica mimetiza los **protocolos clínicos** reales que utilizan los médicos, basados en umbrales y combinaciones de factores, superando la capacidad de modelos lineales simples como la Regresión Logística.

3. Importancia de Variables

El objetivo es proporcionar una herramienta de apoyo a la decisión clínica, por lo que el modelo no puede comportarse como una "Caja Negra". XGBoost permite extraer la **Feature Importance** (importancia de las variables), generando un ranking exacto de qué biomarcadores pesan más en la predicción.

Esto habilita una metodología de validación **Human-in-the-loop**:

- **Validación técnica:** El modelo extrae, por ejemplo, que la *Gravedad Específica (sg)* es la 2ª variable más importante.
- **Validación clínica:** El equipo evalúa conjuntamente si este hallazgo tiene sentido fisiológico (en este caso, la *sg* indica la capacidad de concentración del riñón). Este proceso asegura que la IA aprende patrones causales de la enfermedad y no sesgos de los datos, aportando confianza al usuario final.

4. Estrategia de "Smart Data" y Robustez en Escenarios Limitados

Trabajamos con un dataset clínico focalizado (aprox. 400 pacientes), un escenario conocido como "Small Data". Lejos de ser una desventaja, esto nos ha permitido aplicar una estrategia de **Calidad sobre Cantidad**, evitando el ruido masivo de los grandes lagos de datos hospitalarios.

Para mitigar los riesgos de sobreajuste (*overfitting*) típicos en datasets reducidos, hemos implementado una triple barrera de seguridad técnica:

4.1. Arquitectura Regularizada (XGBoost) y balanceada

A diferencia del Deep Learning, que requiere miles de ejemplos para converger, Gradient Boosting es eficiente con muestras pequeñas. Hemos configurado el modelo con dos mecanismos de robustez:

1. **Regularización:** Utilizamos penalizaciones L1 (Lasso) y L2 (Ridge) para evitar que el modelo memorice el "ruido" de pacientes individuales.
2. **Manejo del desbalanceo:** Aplicamos **Class Weights** (pesos de clase) integrados en el algoritmo para penalizar más el error en la clase minoritaria (enfermos). Esta combinación fuerza al modelo a aprender patrones fuertes y generalizables (ej: *Creatinina Alta* = *Riesgo*) priorizando siempre la sensibilidad del diagnóstico.

4.2. Validación Cruzada Estratificada (Stratified K-Fold)

Para garantizar que nuestros resultados no son fruto del azar al dividir los datos (un riesgo alto con solo 200 filas), no confiamos en una única división *train/test*.

Implementamos una **Validación Cruzada Estratificada (Stratified K-Fold, k=5)**.

- **El proceso:** Entrenamos y evaluamos el modelo 5 veces distintas, rotando los datos de prueba.
- **La estratificación:** Aseguramos que en cada "fold" (subgrupo) se mantenga la proporción exacta de enfermos (40%) y sanos (60%).
- **El resultado:** La métrica final que presentamos es el **promedio** de estas 5 ejecuciones, ofreciendo una estimación realista y honesta del rendimiento del modelo en el mundo real.

4.3. Alta densidad de información ("Smart Data")

Aunque el volumen (N) es bajo, la **prevalencia del evento** es alta (40% de casos positivos de ERC frente al 1-5% habitual en población general). Esto significa que el modelo dispone de una densidad de ejemplos "positivos" suficiente para caracterizar la patología sin necesidad de técnicas agresivas de generación de datos sintéticos que podrían introducir alucinaciones en el diagnóstico.

5. Métricas de evaluación clínica: Más allá del "Accuracy"

En el desarrollo de herramientas de diagnóstico médico, la métrica tradicional de Exactitud (*Accuracy*) puede ser engañosa y peligrosa. No buscamos simplemente acertar el máximo número

de veces en general, sino minimizar el daño potencial al paciente. Por ello, hemos alineado nuestras métricas de éxito con el impacto clínico real del Reto.

5.1. Recall (Sensibilidad)

Nuestra prioridad absoluta es maximizar el **Recall** para la clase positiva (Enfermos).

- **Justificación Clínica:** En una herramienta de cribado (*screening*) para Atención Primaria, el coste de un **falso negativo** (decirle a "Laura" que está sana cuando tiene riesgo de ERC) es inaceptable, ya que implica perder la ventana de oportunidad terapéutica y derivar en complicaciones graves futuras.
- **Estrategia:** El modelo está optimizado para tolerar un ligero aumento en los Falsos Positivos (falsas alarmas), cuya consecuencia es simplemente una revisión médica adicional, frente a la consecuencia crítica de no detectar la enfermedad. Nuestro objetivo técnico es sostener un Recall superior al 90%.

5.2. F1-Score como Medida de Equilibrio

Para asegurar que el modelo no pierde robustez por priorizar la sensibilidad (es decir, que no predice sistemáticamente "enfermo" a todo el mundo), monitoreamos el **F1-Score**.

- **Utilidad:** Al ser la media armónica entre Precisión y Recall, esta métrica nos garantiza que el sistema es fiable y discrimina correctamente, evitando la fatiga de alertas irrelevantes para el médico.

5.3. Transparencia mediante Matriz de Confusión

Finalmente, rechazamos presentar un único número como resultado. Evaluamos el rendimiento mediante la **Matriz de Confusión**, desglosando exactamente cuántos pacientes sanos y enfermos han sido clasificados correctamente. Esto permite una auditoría "Caja Blanca" donde los expertos clínicos pueden revisar los errores puntuales del algoritmo y entender su comportamiento en los casos límite.

5.4 Resultados

Hemos hecho la **matriz de confusión**. Esta muestra que el rendimiento es 100% perfecto, ya que muestra un rendimiento del 100% perfecto donde hay 150 pacientes sanos y 250 pacientes enfermos correctamente clasificados.

Analizando la **curva ROC (fig 5)** se ve que la curva ROC se mantiene muy pegada al vértice superior izquierdo, lo que indica que el modelo consigue una sensibilidad y una especificidad casi

perfectas. El AUC cercano a 1 confirma que el modelo separa excepcionalmente bien a pacientes sanos de enfermos, incluso variando el umbral de decisión.




Fig 4. Matriz de Confusión




Fig 5. Curva ROC

¿Son posibles estos resultados? ¿Por qué salen perfectos? Sí, y las razones son las siguientes:

- El dataset CKD tiene una separación clínica muy fuerte: biomarcadores como creatinina y albúmina distinguen perfectamente entre sanos y enfermos.
- XGBoost es muy potente en datos tabulares y capta reglas clínicas no lineales, por eso acierta casi siempre.
- La validación cruzada estratificada (5-Fold) garantiza que el buen resultado no es por suerte, sino consistente en todas las particiones.
- Las nuevas variables (history_score, bp_alarm, renal_risk_ratio) hacen la separación aún más clara, facilitando predicciones perfectas.

Por último, es importante remarcar que **este 100% de encierto solo aplica a este dataset concreto**, que es muy limpio y muy separable. La curva de aprendizaje del modelo muestra que, aunque el entrenamiento alcanza valores casi perfectos, la precisión de validación nunca llega realmente al 100%. Esto evidencia que, ante datos más complejos y heterogéneos —como los que se encuentran en un **entorno clínico real**, **el modelo no mantendría un rendimiento perfecto**. En la práctica, es esperable que la presencia de variabilidad entre pacientes, diferencias en los procesos analíticos y registros incompletos reduzcan de forma natural la precisión del sistema.

¿Pero podemos comprobar como el modelo va aprendiendo? **La curva de aprendizaje** es la mejor prueba para comprobar si un modelo que obtiene resultados muy altos realmente está

aprendiendo o simplemente está memorizando. Por eso la analizamos, para ver si nuestro rendimiento perfecto es fiable y no un caso de sobreajuste.

Al principio, cuando el modelo sólo dispone de unos pocos pacientes, la precisión de validación es baja porque todavía no ha aprendido patrones clínicos sólidos. Sin embargo, a medida que aumentamos el número de ejemplos, la curva verde sube de forma progresiva hasta estabilizarse muy cerca de la curva de entrenamiento. Esta evolución demuestra que el modelo está aprendiendo de verdad, generaliza bien y que el resultado perfecto final no es sospechoso, sino coherente con el proceso de aprendizaje.




Fig 6. Curva de aprendizaje

El gráfico de **validación real (Fig 7)** muestra que solo tres variables son realmente decisivas: **sg**, **renal_risk_ratio** y **hemo**, siendo **sg** la más importante porque refleja directamente la función renal. Además, vuestra variable creada (**renal_risk_ratio**) aparece como una de las más relevantes, validando vuestra feature engineering. El resto de variables apenas afectan al rendimiento, lo que indica que la señal clínica está muy concentrada. En conjunto, demuestra que el modelo aprende patrones reales y no ruido.




Fig 7. Validación real

El siguiente gráfico muestra como de **segura** está la IA (**Fig 8**) cuando predice si un enfermo está sano o enfermo. Cada barra representa cuántos pacientes reciben una probabilidad a 0 (sano) o a 1 (enfermo).

-Distribución completamente bimodal: el modelo no duda y por lo tanto las predicciones se agrupan casi exclusivamente en:

0.0: pacientes que el modelo considera claramente sanos

1.0: pacientes que considera claramente enfermos

La zona intermedia (0.2-0.8) prácticamente no se utiliza, lo que significa que el modelo no tiene casos ambiguos.

-El modelo está completamente seguro de sus decisiones: La IA predice siempre casi certezas muy cerca de 0 o de 1, por lo tanto, si el modelo está tan seguro, es porque realmente distingue muy bien ambos grupos.

-La línea roja (0.5) separa el sano del enfermo: Como casi ningún enfermo está cerca del umbral, el modelo no está confundido.




Fig 7. Histogramas de probabilidad del modelo

El gráfico **SHAP** (Fig 8) muestra cómo cada variable empuja la predicción hacia “sano” o “enfermo” indicando su impacto real en el modelo. Las más importantes son renal_risk_ratio, hemo y sg que coinciden con los biomarcadores clínicos clave. Los puntos rosados (valores altos) y azules (valores bajos) permiten ver cómo cada valor aumenta o reduce el riesgo. En conjunto, el gráfico demuestra que el modelo toma decisiones basadas en patrones médicos reales y coherentes.




Fig 8. Impacto Clínico de Variables (SHAP)

El gráfico de **Top Variables Clave (Fig 9)** muestra cuáles son las variables que más contribuyen a la predicción del modelo según su importance score. Las más relevantes son hemoglobina (hemo) y renal_risk_ratio, ambas con puntuaciones altísimas, lo que confirma que la anemia y la interacción creatinina–albúmina son biomarcadores críticos en la enfermedad renal. En tercer lugar aparece sg (gravedad específica), que refleja la capacidad del riñón para concentrar la orina. El resto de variables tienen un peso mucho menor, lo que demuestra que el modelo detecta unos pocos marcadores clínicos muy fuertes como principales responsables de la predicción.




Fig 9. Top Variables Clave (según IA)

INTERFAZ GRÁFICA

Nuestra interfaz es el primer paso hacia una herramienta clínica inteligente diseñada para mejorar la detección temprana de la enfermedad renal crónica. Lo que ofrecemos es una plataforma sencilla, intuitiva y lista para adaptarse en cualquier entorno sanitario con los ajustes necesarios.

Hemos elegido Streamlit porque en el Hackathon el tiempo es muy limitado y necesitábamos una forma rápida y eficiente de construir una interfaz visual.

¿Cuáles son los beneficios?




Fig 10. Esquema de los beneficios de la interfaz

Este software ofrece múltiples ventajas en el abordaje del riesgo renal. A continuación, se presentan sus principales beneficios:

-Identificación precoz del riesgo:

Una de las mayores fortalezas de este software es su capacidad para anticiparse. Detecta de forma precoz a los pacientes en riesgo mucho antes de que aparezcan signos clínicos evidentes. Además, permite un seguimiento continuo y preciso, monitorizando la evolución del riesgo y evitando que los pacientes progresen a fases avanzadas. Detectar antes significa intervenir antes, y eso se traduce en frenar o incluso ralentizar el deterioro renal

-Factores económicos:

El modelo de inteligencia artificial trabaja con datos procedentes de analíticas rutinarias, pruebas económicas, rápidas y accesibles que ya forman parte del control médico habitual. Esto elimina la necesidad de estudios complejos o costosos y permite llegar a más pacientes sin esfuerzo adicional. El sistema reduce costes de manera significativa porque detectar la enfermedad en sus

primeras fases es infinitamente más barato que tratarla cuando ya está avanzada.

Además, la herramienta optimiza el tiempo del personal. Su naturaleza escalable permite aplicarla a un volumen masivo de pacientes sin aumentar la carga asistencial.

-Reducción de la variabilidad clínica:

Este software elimina una de las grandes barreras de la práctica clínica, la variabilidad en la interpretación de resultados. Proporciona diagnósticos objetivos y fiables, asegurando que todos los pacientes sean evaluados con los mismos criterios.


-Eficiencia clínica:


La herramienta ofrece alertas inmediatas cuando identifica un riesgo elevado, permitiendo actuar con rapidez y priorizar la atención según la gravedad. En consecuencia, la experiencia del paciente mejora notablemente: evaluación más rápida, decisiones más fundamentadas y un seguimiento mucho más claro y personalizado.

Flujo y Diseño de la Interfaz

La aplicación web, desarrollada en Streamlit (app.py), está diseñada como un Sistema de Soporte a la Decisión Clínica (CDSS) para el médico de Atención Primaria.

- **Carga de Datos:** El proceso inicia en la barra lateral. Aquí se simula la conexión a la base de datos del hospital mediante un **cargador CSV**. — *En producción, esto se conectaría directamente al **EHR** (Electronic Health Record).*
- **Selección de Paciente:** Una vez cargados los datos, el médico busca y selecciona un paciente específico por su **CIP/ID**. Esta acción desencadena la predicción del modelo XGBoost.





Módulo Central: Explicabilidad

Al seleccionar un paciente, la información se organiza en tres pestañas bajo el concepto de **Guardarraíl Clínico**:

Pestaña 1: Historia

- Muestra los datos clínicos y las variables preprocesadas del paciente.
- **Resultado de Riesgo:** La IA clasifica al paciente bajo la **Lógica del Semáforo** (Bajo, Moderado, Alto), con la acción clínica ya prescrita.
- **Explicabilidad Local:** Un panel de **Factores Determinantes (basado en SHAP)** muestra qué variables (e.g., Tensión arterial, Ratio Renal Crítico) fueron las más influyentes para la predicción de ese paciente en concreto.
- **Pestaña 2: Analítica**
 - Proporciona el desglose de las variables analíticas más relevantes de todos los biomarcadores, permitiendo al médico validar el contexto de la predicción de la IA.
- **Pestaña 3: Plan de Seguimiento (Gestión Crónica)**
 - Este módulo ilustra la capacidad de la herramienta para la gestión longitudinal.
 - Muestra un gráfico de Evolución Proyectada de la Creatinina, visualizando la trayectoria potencial de la enfermedad y la efectividad de la acción prescrita.

Debajo de las 3 pestañas y antes del diagnóstico, se puede visualizar los datos sin procesar del historial y las analíticas completas del paciente en cuestión.

Renal Care AI

Hackathon Boehringer 2025

Modo Auditoría

Inicio

Consulta Médica

Equipo

Historia Clínica Digital

Cargar dataset (CSV)

Drag and drop file here

Limit 200MB per file • CSV

Browse files

localhost:8501

Dep

Consulta de Atención Primaria

Buscador de Pacientes

Buscar Paciente (CIP/ID):

PAC-001 (Pedro - Sano)

Ficha Clínica: PAC-001 (Pedro - Sano)

Historia Analítica Seguimiento

Edad

Presión Arterial

Hipertensión / Diabetes

Edema / Apetito

35 años

70 mmHg

No / No

No / Bueno

> Ver Registro Completo

Renal Care AI

Hackathon Boehringer 2025

Modo Auditoría

Inicio

Consulta Médica

Equipo

Historia Clínica Digital

Cargar dataset (CSV)

Drag and drop file here

Limit 200MB per file • CSV

Browse files

localhost:8501

Dep

Buscador de Pacientes

Buscar Paciente (CIP/ID):

PAC-001 (Pedro - Sano)

Ficha Clínica: PAC-001 (Pedro - Sano)

Historia Analítica Seguimiento

Creatinina (sc)

Albúmina Orina (al)

Densidad Orina (sg)

0.8 mg/dL

Negativo (0)

1.025

Hemoglobina (hemo)

Glucosa (bgr)

15.5 g/dL

90 mg/dL

> Ver Registro Completo

Renal Care AI

Hackathon Boehringer 2025

Modo Auditoría

Inicio

Consulta Médica

Equipo

Historia Clínica Digital

Cargar dataset (CSV)

Drag and drop file here

Limit 200MB per file • CSV

Browse files

Ficha Clínica: PAC-001 (Pedro - Sano)

Historia Análítica Seguimiento

Plan de Seguimiento y Evolución

Este módulo simula la funcionalidad de gestión crónica. Su integración requiere la conexión a los sistemas EHR del hospital (datos históricos longitudinales).

Trazabilidad de Acciones

Aquí se mostraría la acción recomendada junto a la fecha de la próxima cita.

Próxima Acción Prescrita: Vigilancia Activa (3 meses)

Evolución de la Función Renal

Evolución de la Función Renal (Simulación Proyectada) para monitorizar la curva de la Creatinina o del eGFR del paciente a lo largo del tiempo.

Renal Care AI

Hackathon Boehringer 2025

Modo Auditoría

Inicio

Consulta Médica

Equipo

Historia Clínica Digital

Cargar dataset (CSV)

Drag and drop file here

Limit 200MB per file • CSV

Browse files

35 años

70 mmHg

No / No

No / Bueno

Ver Registro Completo


	0
age	35
bp	70
sg	1.025
al	0
su	0
rbc	0
pc	0
pcc	0
ba	0
bgr	90

Dashboard de Auditoría y Validación

Una página oculta diseñada para la validación técnica y la *compliance*, demostrando que la herramienta no es una "caja negra" y que cumple con el criterio de seguridad más alto.

Contenido (Evidencias de Robustez):

- Capacidad de Separación: Muestra la Curva ROC (AUC ≈ 1.0) y la Matriz de Confusión, destacando el Cero Falsos Negativos (Recall del 100%).
- Curvas de Aprendizaje: Demuestran que las curvas de entrenamiento y validación convergen, probando que el modelo generaliza bien y no ha memorizado los datos (cero *overfitting*).
- Importancia de Variables (Permutation Importance): Muestra el *ranking* de variables que el modelo utiliza de forma más crítica, validando que la IA se enfoca en los biomarcadores correctos.



Ejemplos

Para hacer las pruebas hemos creado un pequeño dataset de pacientes que representas los posibles outputs que podría asignar la IA a los pacientes.

id	age	bp	sg	al	su	rbc	pc	pcc	ba	bgr	bu	sc	sod	pot	hemo	pcv	wc	rc	htn	dm	cad	appet	pe	ane
PAC-001 (Pedro - Sano)	35	70	1.025	0	0	normal	normal	notpresent	notpresent	90	30	0.8	140	4.5	15.5	45	7000	5.5	no	no	no	good	no	no
PAC-002 (Marta - Grave)	68	160	1.01	3	2	abnormal	abnormal	present	notpresent	250	90	4.2	130	5.8	9.2	30	12000	3.1	yes	yes	yes	poor	yes	yes
PAC-003 (Carmen - Oculto)	50	140	1.015	0	0	normal	normal	notpresent	notpresent	110	40	1.0	138	4.1	11.5	36	8000	4.0	yes	yes	no	good	no	no
PAC-004 (Abuelo - Estable)	80	130	1.02	0	0	normal	normal	notpresent	notpresent	100	50	1.1	135	4.8	13.5	41	6000	4.2	yes	no	no	good	no	no
PAC-005 (Ana - Agudo)	25	110	1.015	2	0	abnormal	abnormal	notpresent	present	95	25	1.0	142	4.0	12.0	38	15000	4.8	no	no	no	good	yes	no

Como podemos observar cada paciente se puede ver el riesgo que tiene (si es alto, bajo o moderado), cuáles son los factores determinantes y cuál es el análisis de riesgo.

Paciente 1

El sistema clasifica un **riesgo bajo**, con un perfil estable y sin anomalías relevantes. Se recomienda mantener hábitos saludables y hacer una revisión anual.

Análisis de Riesgo

BAJO
Seguimiento Rutinario

Factores Determinantes:
Perfil estable. No se detectan anomalías graves.

Análisis de Riesgo
CONTROL RUTINARIO: Mantener hábitos saludables y revisión anual.

Paciente 2

Presenta un **riesgo alto** debido a múltiples alteraciones clínicas detectadas. Se aconseja una derivación urgente, solicitar eGFR y valoración por nefrología.

Análisis de Riesgo

ALTO
Perfil Compatible con ERC Avanzada

Factores Determinantes:
MULTIPATOLOGÍA (3): Hipertensión, Diabetes Mellitus, Enf. Coronaria.
DAÑO FILTRANTE SEVERO: Ratio Renal Crítico (16.80).
ANEMIA DETECTADA: Hemoglobina baja (9.2).
DIAGNÓSTICO ANEMIA: Historial de anemia (Refuerza el valor de Hemoglobina baja).
EDEMA PEDIO: Signo físico de retención de líquidos.
PÉRDIDA DE APETITO: Síntoma asociado a la acumulación de toxinas (uremia).
HTN Descontrolada: Presión arterial alta o historial descontrolado.

Análisis de Riesgo ⇄
DERIVACIÓN URGENTE: Solicitar eGFR y derivar a Nefrología. Daño visible.

Paciente 3

Presenta **un riesgo medio** debido a hipertensión, diabetes, anemia y valores renales en el límite. Se recomienda vigilancia activa: repetir analítica en 3 meses y controlar estrictamente TA y glucosa.

Análisis de Riesgo

MEDIO
Alerta Temprana - Vigilancia

Factores Determinantes:
MULTIPATOLOGÍA (2): Hipertensión, Diabetes Mellitus.
Ratio Renal EN ALERTA: Valores limítrofes (1.00).
ANEMIA DETECTADA: Hemoglobina baja (11.5).
HTN Descontrolada: Presión arterial alta o historial descontrolado.

Análisis de Riesgo
VIGILANCIA ACTIVA: Repetir analítica en 3 meses y control estricto de TA/Glucosa.

Paciente 4

El sistema clasifica **un riesgo bajo**, con un perfil estable y sin anomalías relevantes. Se recomienda mantener hábitos saludables y hacer una revisión anual.

Análisis de Riesgo

BAJO
Seguimiento Rutinario

Factores Determinantes:
MULTIPATOLOGÍA (1): Hipertensión.
Ratio Renal EN ALERTA: Valores limítrofes (1.10).
HTN Descontrolada: Presión arterial alta o historial descontrolado.

Análisis de Riesgo
CONTROL RUTINARIO: Mantener hábitos saludables y revisión anual.

Paciente 5

Presenta **un riesgo medio** debido a hipertensión, diabetes, anemia y valores renales en el límite. Se recomienda vigilancia activa: repetir analítica en 3 meses y controlar estrictamente TA y glucosa.

Análisis de Riesgo

MEDIO
Alerta Temprana - Vigilancia

Factores Determinantes:
DAÑO FILTRANTE SEVERO: Ratio Renal Crítico (3.00).
ANEMIA DETECTADA: Hemoglobina baja (12.0).
EDEMA PEDIO: Signo físico de retención de líquidos.

Análisis de Riesgo
VIGILANCIA ACTIVA: Repetir analítica en 3 meses y control estricto de TA/Glucosa.

CONCLUSIÓN

El caso de Laura, que es una mujer de 61 años con hipertensión, ilustra una realidad muy común, pacientes con factores de riesgo claros que pueden desarrollar una enfermedad renal crónica sin presentar síntomas evidentes durante años. Esta falta de señales tempranas dificulta el diagnóstico oportuno y aumenta la probabilidad de complicaciones cardiovasculares o incluso la necesidad de diálisis, afectando gravemente la calidad de vida. Por ello, resulta esencial contar con herramientas digitales capaces de analizar la historia clínica completa y detectar de forma anticipada aquellos patrones de riesgo que pueden pasar desapercibidos en una consulta rutinaria.

Nuestro proyecto nace precisamente para dar respuesta a esta necesidad, proporcionando a los profesionales una herramienta que facilite una identificación temprana, objetiva y fundamentada del riesgo renal. A lo largo del Hackathon, hemos comprobado el valor de integrar conocimiento médico y técnicas avanzadas de inteligencia artificial para construir una solución útil y aplicable en la práctica real.

Consideramos que una buena organización y una planificación sólida han sido la base de nuestro trabajo. La formación biomédica de Eva y la especialización en inteligencia artificial de Miriam han permitido formar un equipo multidisciplinar y complementario. Este proceso nos ha hecho aprender muchísimo, reforzando la importancia de definir roles claros, coordinar el trabajo y avanzar hacia una solución metódica y bien estructurada.